

Cardiovascular Disease Diagnosis

Fery Kurniawan




Kasus Penyakit Jantung

Cardiovascular disease (CVDs) atau penyakit jantung merupakan penyebab kematian nomor satu secara global dengan 17,9 juta kasus kematian setiap tahunnya.

Deteksi dini penyakit jantung perlu dilakukan pada kelompok risiko tinggi agar dapat segera mendapatkan penanganan dan pencegahan.

Sehingga tujuan bisnis yang ingin dicapai yaitu membentuk model prediksi penyakit jantung pada pasien berdasarkan feature-feature yang ada untuk membantu para dokter melakukan diagnosa secara tepat dan akurat. Harapannya agar penyakit jantung dapat ditangani lebih awal.



Source: AmeriStat, analysis of data from the National Center for Health Statistics.

Data Collecting

Dataset yang digunakan adalah data Heart Disease yang diakses dari UCI ML:

<https://archive.ics.uci.edu/dataset/45/heart+disease>

Dataset yang digunakan ini berasal dari tahun 1988 dan terdiri dari empat database, yaitu Cleveland, Hungaria, Swiss, dan Long Beach V. Bidang "target" mengacu pada adanya penyakit jantung pada pasien. Ini adalah bilangan bulat bernilai 0 = tidak ada penyakit dan 1 = penyakit.

Tools Used:



EXPLORATORY DATA ANALYSIS

Handling Unexpected and Missing Value

```
categorical_col = data.select_dtypes(exclude=['int64', 'float64'])  
for i in categorical_col:  
    print("Kolom {}: {}".format(i, data[i].unique()))
```

```
Kolom sex: ['Male' 'Female']  
  
Kolom cp: ['typical angina' 'atypical angina' 'non-anginal pain' 'asymptomatic']  
  
Kolom fbs: ['No' 'Yes']  
  
Kolom restecg: ['normal' 'probable or definite left ventricular hypertrophy'  
               'ST-T Wave abnormal']  
  
Kolom exang: ['No' 'Yes']  
  
Kolom slope: ['upsloping' 'downsloping' 'flat']  
  
Kolom ca: ['Number of major vessels: 2' 'Number of major vessels: 0'  
           'Number of major vessels: 1' 'Number of major vessels: 3' 4]  
  
Kolom thal: ['reversible defect' 'fixed defect' 'normal' 0]  
  
Kolom target: ['No disease' 'Disease']
```

Terdapat dua features yang mengalami kesalahan penulisan:

1. Feature 'CA': Memiliki 5 nilai dari rentang 0-4, maka dari itu nilai 4 diubah menjadi NaN (karena seharusnya tidak ada)
2. Feature 'thal': Memiliki 4 nilai dari rentang 0-3, maka dari itu nilai 0 diubah menjadi NaN (karena seharusnya tidak ada)

Handling Unexpected and Missing Value

Check missing values

```
print("Hasil missing value:\n", data.isnull().sum())
```

Memeriksa duplikat data

```
print(f'data duplikat: {data.duplicated().sum()}')
```

Hasil missing value:

```
age      0
sex      0
cp       0
trestbps 0
chol     0
fbs      0
restecg  0
thalach  0
exang    0
oldpeak  0
slope    0
ca       18
thal     7
target   0
dtype: int64
```

Terdapat dua features yang memiliki missing value dan terdapat 723 records duplikasi.

```
data duplikat: 723
```

Fillna pada kolom 'ca' dengan modus

```
modus_ca = data['ca'].mode()[0]
```

```
data['ca'] = data['ca'].fillna(modus_ca)
```

Fillna pada kolom 'thal' dengan modus

```
modus_thal = data['thal'].mode()[0]
```

```
data['thal'] = data['thal'].fillna(modus_thal)
```


Menghapus data duplikat

```
data.drop_duplicates(keep='first', inplace=True)
```

Oleh karena itu, akan dilakukan drop value untuk duplicated record dan impute mode untuk missing value.


Visualisasi

Variabel Numerik




Visualisasi

Variabel Kategorik



Visualisasi

Korelasi Antar Variabel



Perhatikan bahwa variabel trestbps, fbs, chol, dan restecg berkorelasi lemah dengan variabel target.

DATA PREPROCESSING

Feature Selection

Dari analisis korelasi, diperoleh bahwa:

1. ca -0.456989 (Korelasi Negatif Kuat)
2. oldpeak -0.434108 (Korelasi Negatif Kuat)
3. exang -0.431599 (Korelasi Negatif Kuat)
4. thal -0.370759 (Korelasi Negatif Kuat)
5. sex -0.318896 (Korelasi Negatif Kuat)
6. age -0.222416 (Korelasi Negatif)
7. trestbps -0.115614 (Korelasi Negatif Lemah)
8. chol -0.0105627 (Korelasi Negatif Lemah)
9. fbs 0.027210 (Korelasi Positif Lemah)
10. restecg 0.171453 (Korelasi Positif Lemah)
11. slope 0.326473 (korelasi Positif Kuat)
12. cp 0.422559 (korelasi Positif Kuat)
13. thalach 0.432211 (korelasi Positif Kuat)

Kesimpulan:

1. 'cp', 'thalach', dan 'slope' berkorelasi positif cukup kuat dengan 'target'.
2. 'oldpeak', 'exang', 'ca', 'thal', 'sex', dan 'age' berkorelasi cukup kuat dengan 'target'.
3. 'fbs', 'chol', 'trestbps', dan 'restecg' memiliki korelasi yang lemah dengan 'target'.

Feature yang dipilih yaitu : 'cp', 'thalach', 'slope', 'oldpeak', 'exang', 'ca', 'thal', 'sex', dan 'age' untuk analisa lebih lanjut.

Label Encoding

Setelah dilakukan analisis terhadap variabel numerik dan kategorik, perlu dilakukan label encoding untuk mengganti kembali nilai pada variabel kategorik menjadi label numerik.

Label encoding memastikan bahwa proses data dapat dilanjutkan ke tahap pemodelan.

Terdapat beberapa cara untuk melakukan label encoding, beberapa di antaranya adalah dengan method replace pada dataframe atau dengan function LabelEncoder yang disediakan oleh scikit-learn.

Contoh dengan function:

```
from sklearn.preprocessing import LabelEncoder
```

```
cat_col = df.select_dtypes('object')
```

```
encoder = {}
```

```
for m in cat_col.columns.tolist():
```

```
    label_encoder = LabelEncoder()
```

```
    df[m] = label_encoder.fit_transform(df[m])
```

```
    encoder[m] = label_encoder
```

Data Transformation


Dengan memperhatikan analisis distribusi variabel, data akan ditransformasi menggunakan scaling StandardScaler.

```
scaler = StandardScaler()
```

```
X_scaled = scaler.fit_transform(X)
```

Hal ini bertujuan untuk membuat data menjadi berdistribusi normal, yaitu dengan $\mu = 0$ dan $\sigma = 1$.


$$z = \frac{x - \mu}{\sigma}, \quad \begin{array}{l} \mu = \text{Mean} \\ \sigma = \text{Standard Deviation} \end{array}$$



PREDICTIVE MODEL

Model Selection

Model terpilih adalah model Multi Layer Perceptron (MLP) Classifier, yang menjadi model dengan performa terbaik di antara 3 model lain yang diterapkan, yaitu Decision Tree, Random Forest, Logistic Regression, dan baseline model menggunakan mode imputer.



Performance metrics yang digunakan adalah accuracy dan ROC-AUC score. Kemudian dilakukan cross validation sebagai evaluasi model, dan terakhir hyperparameter tuning untuk mendapat parameter model terbaik.

Berikut hyperparameter model yang digunakan:

```
model = MLPClassifier()  
hyperparams = {'activation': 'relu',  
               'hidden_layer_sizes': (100,),  
               'solver': 'adam'}
```

Digital Dashboard

A screenshot of a digital dashboard for heart disease diagnosis. The dashboard is dark-themed and has a sidebar on the left with a 'Menu' icon, an 'Insight' icon, and a red 'Diagnose' button. Below the sidebar, it says 'Developed by: Fery Kurniawan' and 'Capstone Project: ML and AI Batch 7'. The main area is titled 'Screening' and 'Suggestion'. It is divided into three columns: 'Identity', 'Physical Examination', and 'Symptoms'. The 'Identity' column has fields for 'Enter Your Name' (with a placeholder 'your name...'), 'Select Age' (with a placeholder 'Type your age...'), and 'Select Gender' (with radio buttons for 'Male' and 'Female'). The 'Physical Examination' column has fields for 'Maximum Heart Rate' (with a placeholder 'in bpm...'), 'ST Depression' (with a placeholder 'in mm...'), 'ST Segment Slope' (with a dropdown 'select ST slope...'), 'Select Blood Disorder' (with a dropdown 'thallium Scan...'), and 'Number of Major Vessels' (with a slider from 0 to 3). The 'Symptoms' column has a dropdown for 'Chest Pain Type' (with a placeholder 'select CP type...') and a radio button for 'Does Exercise Induced Angina?' (with options 'Yes' and 'No'). At the bottom of the main area is a 'Submit' button. In the top right corner of the dashboard, there is a 'Fork this app' link and a 'Manage app' link.

Dapat diakses melalui desktop pada link berikut

<https://heart-disease-diagnosis-capstone-project.streamlit.app/>

**Project ini diharapkan dapat berguna
untuk kajian diagnosa penyakit
menggunakan Machine Learning**

 : fery.kurniawan172@gmail.com

 : <https://www.linkedin.com/in/fery-kurniawan/>



dqlab



www.dqlab.id

Thanks!